CẨM NANG ÔN THI KHAI PHÁ DỮ LIỆU LỚN

5 Dạng Tự Luận Trọng Tâm (Bài 4, 5, 6, 7) – Đã Kiểm Tra & Hiệu Đính Ví Dụ

Tài liệu hệ thống hóa theo phương pháp Feynman – Công thức – Chạy tay (Trace)

Điểm hiệu đính quan trọng trong ví dụ gốc

Qua rà soát kỹ toàn bộ phép tính trong văn bản bạn gửi, có **1 điểm không khớp ở Ví dụ Chạy tay Dạng 1 (HITS)** đã được sửa lại chuẩn xác trong tài liệu này:

- **Lỗi trong bản nháp gốc:** Đồ thị ghi `A -> B, C` (tức A trỏ đến cả B và C), nhưng ma trận kề L lại viết hàng 1 là $[0\ \ 1\ \ 0]$ (thiếu mất cạnh $A \to C$, biến đồ thị thành vòng tròn đối xứng $A \to B \to C \to A$ nên điểm mới bằng nhau $[1,1,1]^T$).
- **Cách khắc phục trong PDF này:** Trình bày rõ **cả 2 trường hợp** cho Dạng 1:
  1. **Trường hợp chuẩn theo đúng đề bài ($A \to B, C$; $B \to C$; $C \to A$):** Lập đúng ma trận L với $L_{13} = 1$, chạy tay ra điểm phân hóa rõ rệt giữa các trang (C có Authority cao nhất, A có Hub cao nhất) đúng như đề thi thực tế.
  2. **Trường hợp đồ thị chu trình đơn ($A \to B$; $B \to C$; $C \to A$):** Khớp với ma trận $[0\ \ 1\ \ 0;\ 0\ \ 0\ \ 1;\ 1\ \ 0\ \ 0]$ trong bản nháp của bạn để bạn đối chiếu phép nhân.
- Các ví dụ ở **Dạng 2 (TrustRank)**, **Dạng 3 (MinHash)**, **Dạng 4 (LSH)** và **Dạng 5 (PQ & HNSW)** đều đã được kiểm tra lại từng con số và hoàn toàn chính xác.

---

1 Phạm vi ôn tập đã chốt

Dựa trên thông báo đề thi, nội dung tự luận chia thành 3 chủ đề lớn gồm 5 dạng bài:

Câu	Bài	Dạng tự luận trọng tâm
1	Bài 4	HITS – Hub & Authority (Lập ma trận kề L, chạy tay & chuẩn hóa)
2	Bài 4	Topic-Sensitive PageRank / TrustRank & Spam Mass
3	Bài 5	Shingling – Jaccard Similarity – MinHash Signature
4	Bài 6	LSH Banding – Xác suất khuếch đại AND/OR
5	Bài 7	Product Quantization (PQ) & Đồ thị HNSW – Vector Search

Đã loại khỏi phạm vi ôn 5 câu tự luận:

- MapReduce (Bài 2).
- PageRank cơ bản (Bài 3).
- Các dạng bài không thuộc phạm vi Bài 4–7 theo thông báo.

Lưu ý: Câu 5 có thể ra theo hướng PQ hoặc HNSW, vì vậy tài liệu trình bày đầy đủ cả hai nhưng tách rõ công thức và quy trình giải.

2 CHỦ ĐỀ 1. LINK ANALYSIS – PHÂN TÍCH LIÊN KẾT

2.1 DẠNG 1 – BÀI 4: THUẬT TOÁN HITS (HUBS & AUTHORITIES)

Trọng tâm: Lập ma trận kề và chạy tay từng bước.

1. Đặc tả đề bài và mô hình hóa

Đề bài thường gặp: Cho đồ thị web gồm một số trang A, B, C, D và các liên kết có hướng. Yêu cầu:

- Lập ma trận kề L.
- Tính điểm Authority (a) và Hub (h).
- Thực hiện một hoặc nhiều vòng lặp HITS.
- Chuẩn hóa kết quả và xác định trang có Hub, Authority cao nhất.

Giải thích Feynman: Hãy tưởng tượng trên Internet có hai kiểu trang web:

- **Authority (trang có thẩm quyền/uy tín):** Giống như một thư viện chứa tài liệu gốc chất lượng. Nhiều trang uy tín khác dẫn link trỏ đến nó (nhiều cạnh đi vào).
- **Hub (trang trung tâm/điều hướng):** Giống như một trang tổng hợp danh mục tài liệu học tập. Nó biết nhiều nguồn tốt và dẫn link trỏ tới các Authority (nhiều cạnh đi ra).

Hai loại điểm này củng cố lẫn nhau: Một trang là Authority tốt nếu được nhiều Hub tốt trỏ đến; một trang là Hub tốt nếu nó trỏ đến nhiều Authority tốt.

2. Công thức và khởi tạo

Ma trận kề L: Quy ước hàng i là trang xuất phát, cột j là trang đích:

$$L_{ij} = \begin{cases} 1 & \text{nếu có liên kết } i \to j \\ 0 & \text{ngược lại} \end{cases}$$

Lưu ý: Phải đọc kỹ đề bài xem đề quy ước hàng là nguồn hay cột là nguồn. Với quy ước chuẩn trên ($L_{ij} = 1$ khi $i \to j$), hai công thức cập nhật bắt buộc là:

$$\boxed{a = L^T h} \qquad \text{và} \qquad \boxed{h = La}$$

Trong đó: a là véc-tơ Authority, h là véc-tơ Hub, L^T là ma trận chuyển vị của L.

Khởi tạo:

$$h_0 = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

Chuẩn hóa: Thường chuẩn hóa theo chuẩn Euclid (L_2) hoặc chia cho tổng (L_1) / chia cho phần tử lớn nhất (max) tùy yêu cầu đề bài:

$$a' = \frac{a}{\|a\|_2}, \qquad h' = \frac{h}{\|h\|_2} \qquad \text{với } \|x\|_2 = \sqrt{\sum_i x_i^2}$$

Nguyên tắc: Không trộn lẫn hai cách chuẩn hóa trong cùng một bài.

3. Chạy tay từng bước (Trace) – Đã hiệu đính

Ví dụ 1A (Đúng theo đồ thị đề bài): Cho 3 trang A, B, C với các cạnh:

- $A \to B, C$ (Hàng A có cột B, C bằng 1)
- $B \to C$ (Hàng B có cột C bằng 1)
- $C \to A$ (Hàng C có cột A bằng 1)

Bước 0 – Lập ma trận L, L^T và khởi tạo h_0:

$$L = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}, \qquad L^T = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix}, \qquad h_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Vòng 1 – Bước 1: Tính Authority ($a_1 = L^T h_0$):

$$a_1 = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix}$$

Giải thích nhanh: C được cả A và B trỏ tới nên $a_C = h_A + h_B = 1 + 1 = 2$.

Vòng 1 – Bước 2: Tính Hub ($h_1 = La_1$):

$$h_1 = \begin{bmatrix} 0 & 1 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix}$$

Giải thích nhanh: A trỏ tới B và C nên $h_A = a_B + a_C = 1 + 2 = 3$.

Vòng 1 – Bước 3: Chuẩn hóa theo chuẩn L_2:

$$\|a_1\|_2 = \sqrt{1^2 + 1^2 + 2^2} = \sqrt{6} \implies a_1' = \begin{bmatrix} 1/\sqrt{6} \\ 1/\sqrt{6} \\ 2/\sqrt{6} \end{bmatrix} \approx \begin{bmatrix} 0.408 \\ 0.408 \\ 0.816 \end{bmatrix}$$

$$\|h_1\|_2 = \sqrt{3^2 + 2^2 + 1^2} = \sqrt{14} \implies h_1' = \begin{bmatrix} 3/\sqrt{14} \\ 2/\sqrt{14} \\ 1/\sqrt{14} \end{bmatrix} \approx \begin{bmatrix} 0.802 \\ 0.535 \\ 0.267 \end{bmatrix}$$

Kết luận Ví dụ 1A: Sau vòng 1, trang C có điểm Authority cao nhất ($2/\sqrt{6}$), còn trang A có điểm Hub cao nhất ($3/\sqrt{14}$).

Ví dụ 1B (Nếu đồ thị là chu trình đơn $A \to B, B \to C, C \to A$): Khi A chỉ trỏ tới B, ta có ma trận đối xứng vòng:

$$L = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \implies a_1 = L^T h_0 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad h_1 = La_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Chuẩn hóa: $\|a_1\|_2 = \sqrt{1^2 + 1^2 + 1^2} = \sqrt{3} \implies a_1' = h_1' = [1/\sqrt{3},\ 1/\sqrt{3},\ 1/\sqrt{3}]^T$.

4. Điều kiện dừng, sai số và điểm cố định

- Dừng khi véc-tơ sau chuẩn hóa giữa hai vòng liên tiếp thay đổi nhỏ hơn ngưỡng ϵ:

$$\|a_{t+1} - a_t\| < \epsilon \quad \text{và} \quad \|h_{t+1} - h_t\| < \epsilon$$

- Về mặt toán học, thế hai phương trình vào nhau ta có:

$$a \propto (L^T L)a \qquad \text{và} \qquad h \propto (LL^T)h$$

  Nghĩa là khi hội tụ, a và h chính là các véc-tơ riêng chính ứng với trị riêng lớn nhất của hai ma trận đối xứng $L^T L$ và LL^T.

5. Nhận xét, ý nghĩa và Bẫy dễ mất điểm

- **Nhận xét mẫu trong bài thi:** Trang có Authority cao nhất vì nhận được liên kết từ các Hub có trọng số lớn; trang có Hub cao nhất vì trỏ trực tiếp tới các trang có Authority cao. Một trang có thể đồng thời có cả hai điểm cao.
- **5 Bẫy dễ mất điểm:**
  1. Nhầm chiều của ma trận kề L với L^T (nhất là ở Ví dụ 1A khi quên tích cạnh $A \to C$).
  2. Tính Hub trước Authority khi đề cho khởi tạo h_0.
  3. Tính h_1 bằng véc-tơ a_0 cũ thay vì dùng ngay véc-tơ a_1 vừa cập nhật.
  4. Quên chuẩn hóa véc-tơ sau mỗi vòng lặp khiến các con số tăng vọt.
  5. Dùng sai quy tắc chuẩn hóa mà đề bài yêu cầu (ví dụ đề bảo chia cho tổng nhưng lại chia cho căn bậc hai tổng bình phương).

2.2 DẠNG 2 – BÀI 4: TOPIC-SENSITIVE PAGERANK / TRUSTRANK

Trọng tâm: Teleport có thiên vị vào tập hạt giống S và chạy tay.

1. Đặc tả đề bài và mô hình hóa

Đề bài thường gặp: Cho đồ thị web, hệ số β và tập hạt giống $S = \{A, B\}$. Yêu cầu:

- Lập ma trận chuyển trạng thái M và véc-tơ khởi tạo v_0.
- Tính điểm PageRank theo chủ đề (hoặc TrustRank) sau 1–2 vòng lặp.
- Tính chỉ số Spam Mass (nếu có điểm PageRank thường PR và TrustRank TR).

Giải thích Feynman: Hãy tưởng tượng bạn đang tìm tài liệu học Data Science:

- **PageRank thông thường:** Khi chán đi theo link, bạn nhảy ngẫu nhiên (Teleport) đến bất kỳ trang nào trên toàn bộ web với xác suất đều $1/N$.
- **Topic-Sensitive PageRank:** Khi nhảy ngẫu nhiên, bạn chỉ nhảy về các trang thuộc chủ đề Data Science (tập S).
- **TrustRank:** Khi nhảy ngẫu nhiên, bạn chỉ quay về các trang hạt giống đã được chuyên gia kiểm duyệt là đáng tin cậy (tập S) để tránh truyền điểm khởi đầu cho trang rác.

2. Công thức và khởi tạo

Công thức lặp bắt buộc:

$$\boxed{v_{t+1} = \beta M v_t + (1-\beta)\frac{e_S}{|S|}}$$

Trong đó:

- M: Ma trận chuyển theo cột ($M_{ij} = 1/d_j$ nếu $j \to i$, với d_j là bậc ra của trang j).
- β: Hệ số damping (xác suất đi theo liên kết).
- S: Tập hạt giống; $|S|$: số lượng phần tử trong tập S.
- e_S: Véc-tơ chỉ thị của tập S, có giá trị 1 nếu trang $i \in S$ và 0 nếu $i \notin S$.

Khởi tạo chuẩn theo tập hạt giống:

$$v_{0,i} = \begin{cases} 1/|S| & \text{nếu } i \in S \\ 0 & \text{nếu } i \notin S \end{cases}$$

Công thức Spam Mass (Độ nghi vấn trang rác):

$$\boxed{\text{SpamMass}(i) = \frac{PR(i) - TR(i)}{PR(i)} = 1 - \frac{TR(i)}{PR(i)}}$$

3. Chạy tay từng bước (Trace)

Đề bài ví dụ: Cho đồ thị 3 trang: $A \to B, C$; $B \to C$; $C \to A$. Tập hạt giống $S = \{A, B\}$, hệ số $\beta = 0.8$. Tính v_1.

Bước 0 – Lập ma trận chuyển M và véc-tơ khởi tạo v_0:

- Trang A có 2 cạnh ra (B, C) $\implies$ cột 1 của M là $[0,\ 1/2,\ 1/2]^T$.
- Trang B có 1 cạnh ra (C) $\implies$ cột 2 của M là $[0,\ 0,\ 1]^T$.
- Trang C có 1 cạnh ra (A) $\implies$ cột 3 của M là $[1,\ 0,\ 0]^T$.

$$M = \begin{bmatrix} 0 & 0 & 1 \\ 1/2 & 0 & 0 \\ 1/2 & 1 & 0 \end{bmatrix}, \qquad v_0 = \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} \quad (\text{vì } S = \{A, B\}, |S| = 2)$$

Bước 1 – Truyền điểm qua liên kết (Mv_0):

$$Mv_0 = \begin{bmatrix} 0 & 0 & 1 \\ 1/2 & 0 & 0 \\ 1/2 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1/2 \\ 1/2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 1/4 \\ 3/4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.25 \\ 0.75 \end{bmatrix}$$

Bước 2 – Tính lượng Teleport ưu tiên cho tập S:

$$(1-\beta)\frac{e_S}{|S|} = \frac{1-0.8}{2} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0.1 \\ 0.1 \\ 0 \end{bmatrix}$$

Bước 3 – Cộng gộp tìm v_1:

$$v_1 = 0.8 \begin{bmatrix} 0 \\ 0.25 \\ 0.75 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.2 \\ 0.6 \end{bmatrix} + \begin{bmatrix} 0.1 \\ 0.1 \\ 0 \end{bmatrix} = \boxed{\begin{bmatrix} 0.1 \\ 0.3 \\ 0.6 \end{bmatrix}}$$

Kiểm tra bảo toàn tổng xác suất: $0.1 + 0.3 + 0.6 = 1.0$ (Đúng).

4. Điều kiện dừng và Ví dụ tính Spam Mass

- **Điều kiện hội tụ:** $\|v_{t+1} - v_t\|_1 = \sum_i |v_{t+1,i} - v_{t,i}| < \epsilon$. Nếu đề yêu cầu tính vòng 2 thì lấy v_1 nhân tiếp $v_2 = \beta M v_1 + (1-\beta)e_S/|S|$.
- **Ví dụ tính Spam Mass:** Giả sử một trang có $PR = 0.8$ nhưng $TR = 0.2$:

$$\text{SpamMass} = \frac{0.8 - 0.2}{0.8} = 0.75 \quad (75\%)$$

  Chỉ số này dương và khá gần 1, nghĩa là 75% điểm PageRank của trang không đến từ các nguồn đáng tin cậy (có dấu hiệu thao túng liên kết / link spam).

5. Nhận xét, ý nghĩa và Bẫy dễ mất điểm

- **Nhận xét mẫu:** Dù $C \notin S$ (không nhận được điểm Teleport trực tiếp), C vẫn có điểm cao nhất sau vòng 1 (0.6) vì được cả hai trang hạt giống A và B trỏ liên kết trực tiếp tới.
- **5 Bẫy dễ mất điểm:**
  1. Chia lượng Teleport cho tổng số trang N thay vì chia cho $|S|$.
  2. Cộng nhầm lượng Teleport cho cả các trang nằm ngoài tập S.
  3. Ngộ nhận rằng trang ngoài tập S thì điểm luôn bằng 0.
  4. Lập ngược ma trận M (tổng mỗi cột của M bắt buộc phải bằng 1 nếu không có nút cụt).
  5. Quên kiểm tra tổng các phần tử của véc-tơ v_t bằng 1 sau mỗi bước.

3 CHỦ ĐỀ 2. FINDING SIMILAR ITEMS – TÌM ĐỐI TƯỢNG TƯƠNG TỰ

3.1 DẠNG 3 – BÀI 5: SHINGLING – JACCARD – MINHASH

Trọng tâm: Lập ma trận Boolean và chạy tay tạo chữ ký MinHash.

1. Đặc tả đề bài và mô hình hóa

Đề bài thường gặp: Cho các văn bản hoặc tập hợp đặc trưng, yêu cầu:

- Tách tập k-shingle và lập ma trận đặc trưng Boolean M.
- Tính độ tương đồng Jaccard thực tế giữa các cặp văn bản.
- Cho các hàm băm $h_i(x)$, tính ma trận chữ ký SIG (MinHash Signature).
- Ước lượng độ tương đồng Jaccard từ ma trận chữ ký và so sánh.

Giải thích Feynman: Để kiểm tra hai bài luận dài có đạo văn hay không, so sánh từng chữ sẽ cực kỳ chậm. Thay vào đó:

1. Cắt văn bản thành các cụm ký tự ngắn gối lên nhau gọi là **Shingle**.
2. Đánh số thứ tự các Shingle và lập bảng đánh dấu văn bản nào chứa Shingle nào (Ma trận $0/1$).
3. Dùng các hàm băm (giống như xáo trộn thứ tự các dòng) rồi lấy **số nhỏ nhất** mà văn bản đó sở hữu làm chữ ký đại diện (**MinHash**).
4. Tỷ lệ các vị trí chữ ký trùng nhau chính là ước lượng không chệch của độ tương đồng Jaccard!

2. Công thức và khởi tạo

- **A. Tập k-shingle:** Các chuỗi con liên tiếp độ dài k. Ví dụ văn bản `ABCDE` với $k = 2$ cho tập $S(D) = \{\text{AB}, \text{BC}, \text{CD}, \text{DE}\}$.
- **B. Độ tương đồng Jaccard:**

$$\boxed{J(A,B) = \frac{|A \cap B|}{|A \cup B|}}$$

  Ví dụ: $A = \{1,2,3\}, B = \{2,3,4\} \implies A \cap B = \{2,3\}$ (2 phần tử), $A \cup B = \{1,2,3,4\}$ (4 phần tử) $\implies J(A,B) = 2/4 = 0.5$.
- **C. Công thức cập nhật chữ ký MinHash:** Với hàm băm thứ i và văn bản (cột) thứ c:

$$\boxed{\text{SIG}(i,c) = \min_{r\,:\,M(r,c)=1} h_i(r)}$$

  Khởi tạo: Mọi ô trong ma trận chữ ký ban đầu đều đặt bằng vô cùng (SIG$(i,c) = +\infty$).
- **D. Ước lượng Jaccard từ chữ ký (với n hàm băm):**

$$\boxed{\hat{J}(A,B) = \frac{\text{Số dòng chữ ký trùng nhau giữa } A \text{ và } B}{n}}$$

3. Chạy tay từng bước (Trace)

Đề bài ví dụ: Cho 2 văn bản chứa các Shingle: $D_1 = \{0, 2\}$ và $D_2 = \{0, 1, 2\}$. Hàm băm $h(x) = (x + 1) \bmod 3$. Tính chữ ký MinHash cho D_1, D_2.

Bước 1 – Lập bảng Ma trận Boolean và giá trị hàm băm:

Dòng Shingle (r)	D_1	D_2	**Giá trị băm** $h(r) = (r + 1) \bmod 3$
0	1	1	$(0 + 1) \bmod 3 = 1$
1	0	1	$(1 + 1) \bmod 3 = 2$
2	1	1	$(2 + 1) \bmod 3 = 0$

Bước 2 – Khởi tạo chữ ký: $\text{SIG}(D_1) = \infty, \quad \text{SIG}(D_2) = \infty$.

Bước 3 – Duyệt từng dòng Shingle:

- **Xét dòng $r = 0$ ($h(0) = 1$):** Cả D_1 và D_2 đều bằng 1. Vì $1 < \infty$, cập nhật:

$$\text{SIG}(D_1) = 1, \qquad \text{SIG}(D_2) = 1$$

- **Xét dòng $r = 1$ ($h(1) = 2$):**
  - D_1 có bit $0 \implies$ bỏ qua, giữ nguyên $\text{SIG}(D_1) = 1$.
  - D_2 có bit $1 \implies$ so sánh $h(1) = 2 > \text{SIG}(D_2) = 1$, giữ nguyên $\text{SIG}(D_2) = 1$.
- **Xét dòng $r = 2$ ($h(2) = 0$):** Cả D_1 và D_2 đều bằng 1. Vì $0 < 1$, cập nhật:

$$\text{SIG}(D_1) = 0, \qquad \text{SIG}(D_2) = 0$$

Bước 4 – Kết quả: $\boxed{\text{SIG}(D_1) = 0, \quad \text{SIG}(D_2) = 0}$.

4. Tính chất xác suất, Nhận xét và Bẫy dễ mất điểm

- **Tính chất cốt lõi:** Với một hoán vị ngẫu nhiên lý tưởng π, xác suất hai cột có cùng giá trị MinHash bằng đúng độ tương đồng Jaccard: $P(h_\pi(A) = h_\pi(B)) = J(A, B)$.
- **5 Bẫy dễ mất điểm:**
  1. Nhầm lẫn giữa số phần tử giao $|A \cap B|$ và hợp $|A \cup B|$.
  2. Cập nhật nhầm giá trị hàm băm vào cột đang có giá trị bit bằng 0.
  3. Ghi nhầm chỉ số dòng r vào bảng chữ ký thay vì ghi giá trị băm $h(r)$ nhỏ nhất.
  4. Quên phép chia lấy dư (mod) khi tính hàm băm.
  5. Kết luận vội vàng chỉ từ 1 hàm băm (cần nhiều hàm băm để ước lượng hội tụ về Jaccard thực).

3.2 DẠNG 4 – BÀI 6: LOCALITY SENSITIVE HASHING (LSH BANDING)

Trọng tâm: Công thức khuếch đại xác suất AND – OR và phân tích tham số b, r.

1. Đặc tả đề bài và mô hình hóa

Đề bài thường gặp: Cho ma trận chữ ký có n dòng, được chia thành b dải (Bands), mỗi dải gồm r dòng (Rows). Cho độ tương đồng Jaccard của hai tài liệu là s. Yêu cầu:

- Tính xác suất hai tài liệu trở thành cặp ứng viên (Candidate pair).
- Tính xác suất bỏ sót (False Negative) hoặc bắt nhầm (False Positive).
- Tính ngưỡng tương đồng t và giải thích sự thay đổi khi tăng/giảm b, r.

Giải thích Feynman: Giả sử mỗi bài thi được tóm tắt thành 4 con số chữ ký. Chia 4 số thành $b = 2$ nhóm (Bands), mỗi nhóm $r = 2$ số (Rows):

- **Trong 1 nhóm (Cấu trúc AND):** Bắt buộc cả r con số trong nhóm phải trùng khớp hoàn toàn $\implies$ xác suất là s^r.
- **Giữa b nhóm (Cấu trúc OR):** Chỉ cần **ít nhất 1 nhóm** trùng hoàn toàn là hai bài được đưa vào diện nghi vấn (Candidate) $\implies$ xác suất là $1 - (1 - s^r)^b$.

2. Công thức bắt buộc

- **Ràng buộc cấu trúc:** $\boxed{n = b \times r}$
- **Bước 1 (AND – 1 Band trùng cả r hàng):** $\boxed{P(\text{AND}) = s^r}$
- **Bước 2 (1 Band không trùng):** $1 - s^r$
- **Bước 3 (Tất cả b Band đều không trùng – Âm tính giả FN khi s cao):**

$$\boxed{P(\text{FN}) = (1 - s^r)^b}$$

- **Bước 4 (OR – Trở thành Candidate / Dương tính giả FP khi s thấp):**

$$\boxed{P(\text{Candidate}) = 1 - (1 - s^r)^b}$$

- **Ngưỡng đường cong chữ S (Threshold):**

$$\boxed{t \approx \left(\frac{1}{b}\right)^{1/r}}$$

3. Chạy tay từng bước (Trace)

Đề bài ví dụ: Cho $n = 4$ dòng chữ ký, chia thành $b = 2$ Bands, mỗi Band $r = 2$ Rows. Hai văn bản có độ tương đồng $s = 0.8$. Tính xác suất trở thành Candidate và xác suất bị bỏ sót (FN).

1. **Kiểm tra cấu trúc:** $n = b \times r = 2 \times 2 = 4$ (Khớp).
2. **Xác suất 1 Band trùng hoàn toàn (AND):** $P(\text{AND}) = s^r = 0.8^2 = 0.64$.
3. **Xác suất 1 Band không trùng:** $1 - 0.64 = 0.36$.
4. **Xác suất cả 2 Band đều không trùng (Bị bỏ sót – FN):**

$$P(\text{FN}) = (0.36)^2 = \boxed{0.1296 \quad (12.96\%)}$$

5. **Xác suất có ít nhất 1 Band trùng (Trở thành Candidate – OR):**

$$P(\text{Candidate}) = 1 - 0.1296 = \boxed{0.8704 \quad (87.04\%)}$$

4. Phân tích tác động của b và r & Bẫy dễ mất điểm

Thay đổi tham số	Ngưỡng t	Hệ quả đối với False Positive (FP) và False Negative (FN)
Tăng b (giữ r)	Giảm t	Dễ thành Candidate hơn $\Longrightarrow$ **Giảm FN** (ít bỏ sót), nhưng **Tăng FP** (bắt nhầm nhiều, tốn chi phí hậu kiểm).
Giảm b (giữ r)	Tăng t	Khó thành Candidate hơn $\Longrightarrow$ **Giảm FP**, nhưng **Tăng FN**.
Tăng r (giữ b)	Tăng t	Điều kiện AND khắt khe hơn $\Longrightarrow$ **Giảm FP** (ít bắt nhầm), nhưng **Tăng FN** (dễ bỏ sót cặp giống nhau).
Giảm r (giữ b)	Giảm t	Dễ trùng trong mỗi Band hơn $\Longrightarrow$ **Giảm FN**, nhưng **Tăng FP**.

5 Bẫy dễ mất điểm:

1. Nhầm vị trí số mũ giữa b và r: viết sai thành $1-(1-s^b)^r$ (Hãy nhớ: **trong** Band có r hàng nên phải lũy thừa r trước: s^r).
2. Nhầm xác suất trở thành Candidate với xác suất bị bỏ sót (FN).
3. Quên kiểm tra điều kiện $n = b \times r$.
4. Lấy xác suất các Band nhân trực tiếp với nhau thay vì dùng phần bù $1-(1-s^r)^b$.
5. Tưởng ngưỡng $t \approx (1/b)^{1/r}$ là hàm bước nhảy tuyệt đối (thực tế là đường cong chữ S mềm).

4 CHỦ ĐỀ 3. VECTOR SEARCH – TÌM KIẾM VÉC-TƠ

4.1 DẠNG 5A – BÀI 7: PRODUCT QUANTIZATION (PQ)

Trọng tâm: Nén véc-tơ, tính dung lượng bộ nhớ và khoảng cách bất đối xứng (ADC).

1. Đặc tả đề bài và Giải thích Feynman

Đề bài thường gặp: Cho N véc-tơ D chiều lưu kiểu `float32` (4 Bytes/số). Chia mỗi véc-tơ thành m đoạn con, mỗi đoạn lượng tử hóa bằng k tâm cụm (centroids). Yêu cầu tính dung lượng gốc, dung lượng mã PQ, dung lượng bộ từ điển (Codebook) và tỷ lệ tiết kiệm bộ nhớ.

Giải thích Feynman: Thay vì lưu nguyên vẹn $D = 1024$ số thực (tốn 4096 Bytes cho mỗi véc-tơ), PQ cắt véc-tơ thành $m = 8$ khúc ngắn (mỗi khúc 128 số). Ở mỗi khúc, ta gom cụm trước thành $k = 256$ mẫu đại diện (đánh số từ 0 đến 255, chỉ tốn đúng 8 bit $= 1$ Byte để lưu mã số). Khi đó mỗi véc-tơ dài chỉ cần lưu 8 mã số nguyên (tốn đúng 8 Bytes!).

2. Hệ thống công thức bắt buộc

- **A. Dung lượng bộ nhớ gốc (`float32` = 4 Bytes):**

$$\boxed{\text{Memory}_{\text{original}} = N \times D \times 4 \text{ (Bytes)}}$$

- **B. Số chiều của mỗi đoạn con (Sub-vector):** $\boxed{D_{\text{sub}} = \dfrac{D}{m}}$

- **C. Số bit và số Byte cho 1 mã ID tâm cụm:**

$$b_{\text{bits}} = \log_2(k) \text{ (bits)} = \frac{\log_2(k)}{8} \text{ (Bytes)} \quad (\text{Với } k = 256 \implies 8 \text{ bits} = 1 \text{ Byte})$$

- **D. Dung lượng lưu mã nén PQ của N véc-tơ:**

$$\boxed{\text{Memory}_{\text{PQ}} = N \times m \times \frac{\log_2(k)}{8} \text{ (Bytes)}}$$

- **E. Dung lượng bảng từ điển tâm cụm (Codebook):** Có m đoạn, mỗi đoạn lưu k tâm cụm, mỗi tâm cụm có D/m chiều kiểu `float32`:

$$\boxed{\text{Memory}_{\text{Codebook}} = m \times k \times \frac{D}{m} \times 4 = k \times D \times 4 \text{ (Bytes)}}$$

- **F. Tổng dung lượng sau nén và Tỷ lệ tiết kiệm:**

$$\text{Memory}_{\text{total}} = \text{Memory}_{\text{PQ}} + \text{Memory}_{\text{Codebook}}, \qquad \text{Saving} = \left(1 - \frac{\text{Memory}_{\text{total}}}{\text{Memory}_{\text{original}}}\right) \times 100\%$$

- **G. Khoảng cách xấp xỉ ADC (Asymmetric Distance Computation):**

$$\boxed{d(q, \hat{x})^2 \approx \sum_{j=1}^{m} \left\| q^{(j)} - c_{i_j}^{(j)} \right\|^2 = \sum_{j=1}^{m} T[j, i_j]}$$

3. Chạy tay từng bước (Trace)

Đề bài ví dụ: Cho $N = 1.000.000$ véc-tơ, $D = 1024$ chiều, kiểu `float32` (4 Bytes). Chia thành $m = 8$ đoạn, mỗi đoạn có $k = 256$ centroids. Tính bộ nhớ trước và sau khi dùng PQ.

1. **Dung lượng bộ nhớ gốc:**

$$\text{Memory}_{\text{original}} = 1.000.000 \times 1024 \times 4 = \boxed{4.096.000.000 \text{ Bytes} \approx 4.096 \text{ GB}}$$

2. **Số chiều mỗi đoạn con:** $D_{\text{sub}} = 1024/8 = 128$ chiều.
3. **Kích thước 1 mã ID:** $\log_2(256) = 8$ bits $= 1$ Byte.
4. **Dung lượng mã nén PQ cho N véc-tơ:**

$$\text{Memory}_{\text{PQ}} = 1.000.000 \times 8 \times 1 = \boxed{8.000.000 \text{ Bytes} = 8 \text{ MB}}$$

5. **Dung lượng Codebook:**

$$\text{Memory}_{\text{Codebook}} = 8 \times 256 \times 128 \times 4 = \boxed{1.048.576 \text{ Bytes} \approx 1.05 \text{ MB}}$$

6. **Tổng bộ nhớ sau PQ:**

$$\text{Memory}_{\text{total}} = 8.000.000 + 1.048.576 = \boxed{9.048.576 \text{ Bytes} \approx 9.05 \text{ MB}}$$

7. **Tỷ lệ tiết kiệm bộ nhớ:**

$$\text{Saving} = \left(1 - \frac{9.048.576}{4.096.000.000}\right) \times 100\% \approx \boxed{99.78\%}$$

Bẫy dễ mất điểm ở PQ: Quên nhân 4 cho `float32`; quên cộng $\text{Memory}_{\text{Codebook}}$ vào tổng bộ nhớ; hoặc quên chia 8 khi đổi từ số bit ($\log_2 k$) sang Byte (ví dụ với $k = 64 \implies 6$ bits $= 0.75$ Byte).

4.2 DẠNG 5B – BÀI 7: ĐỒ THỊ HNSW (HIERARCHICAL NAVIGABLE SMALL WORLD)

Trọng tâm: Duyệt đồ thị tham lam (Greedy Search), tính khoảng cách Euclid và Recall@K.

1. Giải thích Feynman & Công thức

Giải thích Feynman: HNSW giống như hệ thống giao thông nhiều tầng: Tầng cao nhất chỉ có vài trạm trung chuyển lớn nối xa nhau (đường cao tốc) giúp nhảy thật nhanh đến vùng lân cận đích; các tầng dưới dày đặc dần (đường tỉnh lộ $\rightarrow$ ngõ nhỏ) giúp tìm chi tiết ra đúng điểm gần nhất.

- **Khoảng cách Euclid:** $\boxed{d(q,x) = \sqrt{\sum_{i=1}^{D}(q_i - x_i)^2}}$
- **Độ đo chất lượng tìm kiếm gần đúng:** $\boxed{\text{Recall@}K = \frac{|N_K(q) \cap \hat{N}_K(q)|}{K}}$

- **Ý nghĩa 3 tham số cốt lõi:**
  - M: Số cạnh nối tối đa của mỗi nút (tăng $M \implies$ tăng Recall nhưng tốn RAM và thời gian duyệt).
  - efConstruction: Độ rộng danh sách ứng viên lúc xây dựng đồ thị (tăng $\implies$ đồ thị chất lượng cao hơn nhưng xây lâu hơn).
  - efSearch: Độ rộng danh sách ứng viên lúc truy vấn (tăng $\implies$ tăng Recall nhưng tăng độ trễ tìm kiếm).

2. Chạy tay từng bước (Trace)

Đề bài ví dụ: Cho 4 điểm $A(1,1), B(2,2), C(5,5), D(8,8)$ và điểm truy vấn $q = (2,1)$. Đồ thị có các cạnh: $D - C$, $C - A$, $C - B$, $A - B$. Bắt đầu từ D, mô phỏng Greedy Search tìm hàng xóm gần q nhất.

1. **Tính khoảng cách Euclid tới $q(2,1)$:**
   - $d(q,D) = \sqrt{(2-8)^2 + (1-8)^2} = \sqrt{36+49} = \sqrt{85} \approx 9.22$
   - $d(q,C) = \sqrt{(2-5)^2 + (1-5)^2} = \sqrt{9+16} = 5$
   - $d(q,A) = \sqrt{(2-1)^2 + (1-1)^2} = 1$
   - $d(q,B) = \sqrt{(2-2)^2 + (1-2)^2} = 1$
2. **Quá trình duyệt tham lam:**
   - Xuất phát tại D ($d = \sqrt{85}$). Xét hàng xóm của D là C có $d(q,C) = 5 < \sqrt{85} \implies$ Di chuyển sang C.
   - Tại C ($d = 5$), xét các hàng xóm A ($d = 1$) và B ($d = 1$). Cả hai đều nhỏ hơn $5 \implies$ Di chuyển tới A (hoặc B).
   - Tại A ($d = 1$), không còn hàng xóm nào có khoảng cách nhỏ hơn $1 \implies$ Dừng thuật toán.
3. **Kết luận:** Điểm gần nhất tìm được là $\boxed{A \text{ hoặc } B}$ (cùng khoảng cách bằng 1).

5 BẢNG TỔNG HỢP CÔNG THỨC BẮT BUỘC THUỘC LÒNG

Dạng bài	Tên đại lượng	Công thức chuẩn
1. HITS	Authority & Hub	$a = L^T h, \quad h = La$ (với $L_{ij} = 1$ khi $i \to j$)
	Chuẩn hóa L_2	$a' = a/\|a\|_2, \quad h' = h/\|h\|_2$
	Phương trình đặc trưng	$a \propto (L^T L)a, \quad h \propto (LL^T)h$
2. TrustRank	Công thức lặp	$v_{t+1} = \beta M v_t + (1-\beta)\dfrac{e_S}{\|S\|}$
	Chỉ số Spam Mass	$\text{SpamMass}(i) = \dfrac{PR(i) - TR(i)}{PR(i)}$
3. MinHash	Độ tương đồng Jaccard	$J(A,B) = \dfrac{\|A \cap B\|}{\|A \cup B\|}$
	Chữ ký MinHash	$\text{SIG}(i,c) = \min_{r\,:\,M(r,c)=1} h_i(r)$
	Ước lượng Jaccard	$\hat{J}(A,B) = \dfrac{\text{Số dòng chữ ký trùng nhau}}{n}$
4. LSH	Ràng buộc chia dải	$n = b \times r$
	Xác suất 1 dải trùng (AND)	$P(\text{AND}) = s^r$
	Xác suất bị bỏ sót (FN)	$P(\text{FN}) = (1-s^r)^b$
	Xác suất ứng viên (OR)	$P(\text{Candidate}) = 1-(1-s^r)^b$
	Ngưỡng đường cong S	$t \approx (1/b)^{1/r}$
5A. PQ	Bộ nhớ gốc (`float32`)	$\text{Memory}_{\text{original}} = N \times D \times 4$ (Bytes)
	Bộ nhớ mã nén PQ	$\text{Memory}_{\text{PQ}} = N \times m \times \dfrac{\log_2(k)}{8}$ (Bytes)
	Bộ nhớ Codebook	$\text{Memory}_{\text{Codebook}} = m \times k \times \dfrac{D}{m} \times 4 = k \times D \times 4$ (Bytes)
5B. HNSW	Khoảng cách Euclid	$d(q,x) = \sqrt{\sum_{i=1}^{D}(q_i - x_i)^2}$
	Độ đo Recall@K	$\text{Recall@}K = \dfrac{\|N_K(q) \cap \hat{N}_K(q)\|}{K}$

Khung trình bày 5 bước cho mọi câu tự luận trong phòng thi

1. **Bước 1 – Tóm tắt & Khởi tạo:** Viết rõ các tham số đề cho, lập ma trận (L, M, hoặc bảng Boolean) và véc-tơ khởi tạo (h_0, v_0, SIG_0).
2. **Bước 2 – Viết công thức gốc:** Luôn viết công thức tổng quát ra giấy thi trước khi thay số (chiếm $0.25 - 0.5$ điểm thành phần).
3. **Bước 3 – Chạy tay từng bước (Trace):** Thay số rõ ràng theo từng vòng lặp hoặc từng dòng dữ liệu.
4. **Bước 4 – Kiểm tra chéo (Sanity Check):** Kiểm tra tổng xác suất bằng 1 (với TrustRank), chuẩn bậc 2 bằng 1 (với HITS), hoặc $P(\text{Candidate}) + P(\text{FN}) = 1$ (với LSH).
5. **Bước 5 – Kết luận & Nhận xét ý nghĩa:** Đóng khung kết quả cuối cùng và viết 1–2 câu nhận xét ngắn gọn theo bản chất thuật toán.